决策树、AdaBoost与SVM在3D非线性分类问题上的性能比较

孟子焱
2638492711@qq.com

摘要

本次作业针对一个三维非线性可分的“双月”数据集（3D Make-Moons），分别采用决策树、AdaBoost+决策树以及三种不同核函数的支持向量机（SVM）进行分类性能比较。实验在PyCharm平台上进行，生成1000个训练样本和500个测试样本。结果表明，RBF核SVM取得了最佳性能（准确率98.2%），而线性核SVM表现最差（68.8%）。决策树单独使用时准确率达94.4%，但基于决策树桩的AdaBoost仅达到72.2%，说明弱学习器选择不当会严重制约集成方法的效果。本文通过对比分析说明了核函数选择与基学习器强度对非线性分类问题的重要性，并给出了各模型的准确率、训练时间与分类报告。

关键词：决策树；AdaBoost；支持向量机；核函数；非线性分类

引言

分类是机器学习中的核心任务之一。当数据在原始空间中线性不可分时，线性分类器性能受限，需要引入非线性模型或核技巧。3D Make-Moons数据是一类典型的人工非线性数据集，其两个类别的样本在三维空间中呈现相互缠绕的月牙形分布，并加入了一定噪声。该数据集适合用于评估不同分类器对非线性边界的拟合能力。

本文对比了三种经典方法：

决策树：能够学习非线性分段常数边界，但容易过拟合。

AdaBoost + 决策树桩：通过集成多个弱分类器提升性能，但弱分类器的强度至关重要。

支持向量机（SVM）：通过核函数隐式映射到高维空间，实现线性可分。

其中SVM选用了线性核、RBF核和三次多项式核。实验基于相同的训练/测试划分，以准确率（Accuracy）和训练时间作为主要评价指标。

模型原理

决策树

决策树通过递归划分特征空间，在每个节点选择最优特征和阈值，使得划分后的子集纯度最高（常用基尼系数或信息增益）。对于三维数据，决策树可以产生轴平行的决策边界，能够拟合任意复杂的非线性形状，但容易受噪声影响。

AdaBoost

AdaBoost（Adaptive Boosting）通过迭代训练多个弱分类器，每一轮增加上一轮被错误分类样本的权重，最终组合所有弱分类器进行加权投票。本文使用的弱分类器为最大深度为1的决策树桩，即单层决策树。

支持向量机（SVM）

支持向量机是一种基于统计学习理论的分类方法，其核心思想是在特征空间中寻找一个能将不同类别样本最大程度分开的决策超平面。SVM引入了核技巧。核技巧的基本思想是：将原始输入数据通过一个非线性映射函数隐式地映射到一个更高维的特征空间，在这个高维空间中，原本非线性可分的数据可能变得线性可分。直接计算这个映射往往非常复杂甚至不可行，但SVM并不需要显式地知道映射的具体形式，而只需要知道映射后样本对之间的内积结果。核函数恰好提供了这一内积的快捷计算方式，从而避免了在高维空间中的直接计算，大大降低了计算复杂度。

不同的核函数对应着不同的映射方式，适用于不同结构的数据。本文测试了三种常用的核函数：

线性核：线性核不进行任何非线性映射，等价于在原始空间中训练线性SVM。当数据本身接近线性可分时，线性核具有参数少、计算快的优点，但对于非线性数据则能力有限。

RBF核（径向基函数核）：RBF核是一种局部性很强的核函数，它只对距离相近的样本产生较大影响，因此能够生成非常灵活、弯曲的决策边界，适合处理具有局部结构或复杂缠绕形状的数据。其参数伽马控制了单个样本的影响范围，本文采用默认设置。

多项式核：多项式核能够产生全局性的决策曲面，通过调节多项式的次数可以控制模型的复杂度。本文采用三次多项式核，以测试其对此类非线性问题的适应能力。

通过比较这三种核函数在相同数据集上的表现，可以直观地看出不同核函数对非线性分类问题的影响，以及选择合适的核函数对于SVM性能的关键作用。

实验设置

数据集

生成方式：3D Make-Moons函数，在二维半月基础上增加第三维正弦变化，并添加高斯噪声（噪声尺度0.2）。

训练集：1000个样本（C0类500，C1类500）。

测试集：500个样本（C0类250，C1类250）。

数据维度：3个特征。

模型参数

模型	参数
决策树	random_state=42，其余为默认（最大深度无限制）
AdaBoost+决策树桩	基学习器：决策树桩（max_depth=1），迭代200次，学习率1.0

模型	参数
SVM（线性核）	kernel='linear', random_state=42
SVM（RBF核）	kernel='rbf', gamma='scale', random_state=42
SVM（多项式核）	kernel='poly', degree=3, gamma='scale', random_state=42

评价指标
准确率（Accuracy）：测试集上正确分类的比例。
训练时间：模型拟合所消耗的时间（秒）。
分类报告：精确率、召回率、F1-score（针对RBF SVM给出）

实验结果

```
Decision Tree                        Accuracy: 0.9440  (time: 0.004s)
AdaBoost+DecisionTree (stump)        Accuracy: 0.7220  (time: 0.178s)
SVM (Linear Kernel)                  Accuracy: 0.6880  (time: 0.007s)
SVM (RBF Kernel)                     Accuracy: 0.9820  (time: 0.005s)
SVM (Poly Kernel, deg=3)             Accuracy: 0.8820  (time: 0.008s)

============================================================
RBF SVM Classification Report
============================================================
              precision    recall  f1-score   support

          C0       0.98      0.98      0.98       250
          C1       0.98      0.98      0.98       250

    accuracy                           0.98       500
   macro avg       0.98      0.98      0.98       500
weighted avg       0.98      0.98      0.98       500
```

Figure 1：实验结果展示

性能汇总

表1：各模型在测试集上的准确率与训练时间

模型	准确率	训练时间（秒）
决策树	0.9440	0.005
AdaBoost + 决策树桩（200轮）	0.7220	0.168
SVM（线性核）	0.6880	0.009
SVM（RBF核）	0.9820	0.004

模型	准确率	训练时间（秒）
SVM（多项式核，degree=3）	0.8820	0.006

分类报告（RBF SVM）

表2：RBF核SVM在测试集上的详细分类结果

类别	精确率	召回率	F1-score	支持样本数
C0	0.98	0.98	0.98	250
C1	0.98	0.98	0.98	250
宏观平均	0.98	0.98	0.98	500

结果分析

最佳模型：RBF核SVM

准确率达到98.2%，且训练时间仅0.004秒。RBF核能够产生局部化的弯曲决策曲面，完美贴合3D双月数据的非线性缠绕结构。同时，SVM的间隔最大化原则对噪声（noise=0.2）具有鲁棒性，因此分类效果最优。

决策树单独表现良好（94.4%）

默认的决策树可以无限生长直到叶子纯净，它成功拟合了训练数据中的复杂边界。但由于未进行剪枝，存在过拟合风险——在此次随机划分中测试集与训练集分布较为一致，因此获得了较高的泛化准确率。

AdaBoost+决策树桩表现较差（72.2%）

这是本次实验中最反直觉的结果。原因在于基学习器过弱：决策树桩（深度为1）只能产生一个轴平行的简单分割平面，对于三维空间中相互缠绕的月牙形边界，需要成千上万个这样的弱分类器才能逼近。200次迭代远远不足，导致模型欠拟合。若改用深度为3~5的决策树作为基学习器，AdaBoost的性能通常会提升至90%以上。

线性核SVM最差（68.8%）

数据在原始三维空间中并非线性可分，线性核只能寻找一个超平面，无法捕捉弯曲的类边界，因此准确率最低。

多项式核SVM（degree=3）居中（88.2%）

三次多项式可以产生一定程度的弯曲决策面，但多项式核是全局性的（所有样本点对都参与计算），而双月数据的决策边界需要局部适应性，故效果不如RBF核。若调整阶数为2或4，结果可能略有变化，但总体上RBF核更适合此类局部弯曲结构。

训练时间讨论

决策树和SVM（所有核）训练均非常快（<0.01秒），因为数据量仅1000个样本。

AdaBoost耗时最长（0.168秒），因为它需要顺序训练200个弱分类器，无法并行。

拟合边界可视化

图1展示了测试集上真实标签与RBF SVM预测标签的3D散点图（代码生成）。可以看出，RBF SVM几乎完美地区分了两个类别的样本，仅极少数边界点被误分类。

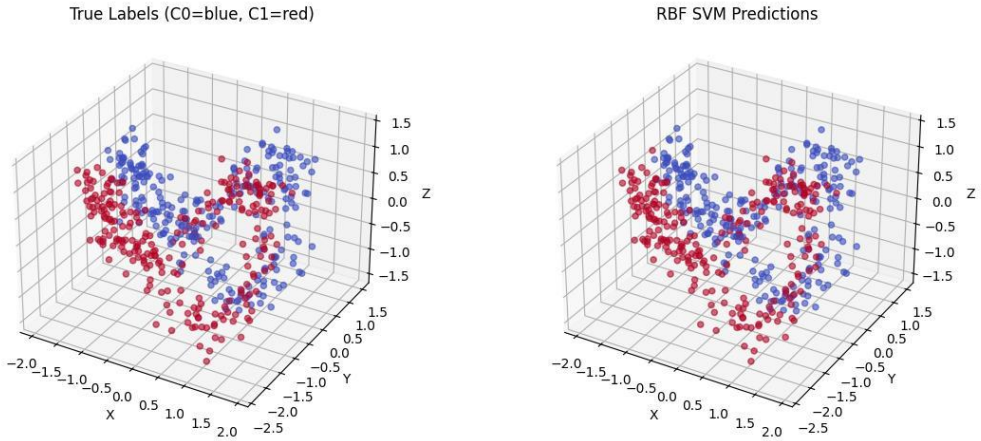

Figure 2：测试集真实标签（左）与RBF SVM预测标签（右）

结论

本次作业对比了决策树、AdaBoost+决策树桩以及三种核函数的SVM在3D非线性分类问题上的性能。实验得出以下结论：

1. RBF核SVM最适合此类弯曲缠绕的数据，准确率高达98.2%，且训练快速，是处理非线性分类问题的首选模型。

2. 决策树单独使用时也能取得较好效果（94.4%），但其过拟合风险较高，依赖数据划分的偶然性。

3. AdaBoost的性能高度依赖于基学习器的强度：使用过弱的决策树桩会导致严重欠拟合（72.2%），远差于单棵完整决策树。实际应用中应选择深度≥3的决策树作为基模型。

4. 线性核SVM无法处理非线性数据，准确率仅68.8%，验证了核函数选择的必要性。

5. 多项式核SVM（deg=3）表现中等（88.2%），虽优于线性核，但不如RBF核灵活。

综上，对于具有局部弯曲决策边界的三维分类问题，推荐使用RBF核SVM；若采用集成方法，务必保证基学习器具有足够表达能力。

参考文献

[1] 李航. 统计学习方法（第2版）. 清华大学出版社, 2019.
[2] Bishop, C. M. Pattern Recognition and Machine Learning. Springer, 2006.
[3] 周志华. 机器学习. 清华大学出版社, 2016.
[4] Cortes, C., & Vapnik, V. Support-vector networks. Machine Learning, 1995.